一、 问题重述

1.1 问题背景

随着精准医疗理念的深入发展和分子生物学技术的不断进步，无创产前检测（Non-invasive Prenatal Testing, NIPT）已成为现代产前诊断的重要技术手段。作为一种基于母体血液中胎儿游离 DNA 检测的新兴技术，NIPT 在唐氏综合征等常见染色体异常筛查中展现出显著优势，目前已在全球范围内得到快速推广。

然而当前临床实践中 NIPT 检测面临检测时点选择面临技术可行性与临床安全性的矛盾：过早检测可因胎儿游离 DNA 浓度不足导致失败率升高，过晚检测虽浓度充足但错过早期干预的黄金窗口，且未能充分考虑孕妇的个体差异。研究表明，cffDNA 浓度受孕周、母体 BMI 等因素显著影响。Wang 等人 (2013) 的研究证实 cffDNA 浓度与孕周呈正相关，孕 10-21 周每周升高 0.1%，21 周后增长至每周 1%。同时，Ashoor 等人 (2012) 的研究发现：孕妇体重与 cffDNA 浓度呈负相关，体重增加导致血容量扩张稀释胎儿 DNA 浓度，肥胖孕妇 NIPT 检测失败风险更高。

此外，对于女胎异常的判定，由于缺乏 Y 染色体，现有方法主要依赖 13、18、21 号染色体的 Z 值分析，但在复杂遗传背景和样本分布不均衡情况下的诊断准确性仍有待提升。因此，构建基于多因素分析的个体化 NIPT 检测时点优化模型，以及寻找更加精准的胎儿异常判定方法，已成为当前产前诊断领域亟待解决的关键科学问题。

1.2 问题提出

为使 NIPT 检测在今后的临床应用中获得更高的检测准确性和更好的风险控制效果，现需结合实际情况与附件所给信息建立数学模型，分析以下问题：

- **问题一：** 分析胎儿 Y 染色体浓度与孕妇的孕周数和 BMI 等指标的相关特性，给出相应的关系模型，并检验其显著性。
- **问题二：** 临床证明，男胎孕妇的 BMI 是影响胎儿 Y 染色体浓度达标时间的主要因素。试对男胎孕妇的 BMI 进行合理分组，给出每组的 BMI 区间和最佳 NIPT 时点，使得孕妇可能的潜在风险最小，并分析检测误差对结果的影响。
- **问题三：** 综合考虑身高、体重、年龄等多种因素及检测误差，根据男胎孕妇的 BMI 给出合理分组以及每组的最佳 NIPT 时点，使得在不同 Y 染色体浓度达标比例要求下孕妇潜在风险最小，并分析检测误差对结果的影响。
- **问题四：** 针对女胎异常判定问题，试以女胎孕妇的 21 号、18 号和 13 号染色体非整倍体为判定结果，综合考虑 X 染色体、21 号/18 号/13 号染色体

Z 值、GC 含量、读段数及相关比例，BMI 指标等因素，给出女胎异常判定方法。

二、 问题分析

2.1 问题一的分析

针对问题一，首先要分析胎儿 Y 染色体浓度与孕妇的孕周数和 BMI 等指标的相关性。接着需要给出相应的关系模型，并检验其显著性。鉴于数据存在重复测量，且个体间和个体内变异的层次结构特点，研究选择线性混合效应模型（LMM）作为核心建模工具，并采用受限最大似然估计（REML）进行参数估计。模型结果显示，回归系数均显著，且 Wald^2 检验表明固定效应具有联合显著性。此外，研究结合 AIC/BIC 准则进行模型比较，并进行随机截距正态性检验与同方差性检验，以全面验证模型假设的合理性。

2.2 问题二的分析

首先，题干明确指出 BMI 是影响达标时间的主要因素，因此需要在 BMI 这一连续变量上寻找最优的分割点。之后，需要为每个独立的 BMI 分层群体计算出一个能使整体潜在风险最小化的最佳 NIPT 检测时点。并且再检误差不同的情况下，分组边界及最佳时点均可能不同。

为此，需构建一个两阶段的求解框架。第一阶段考虑到原始观测数据的稀疏性与噪声干扰，先为每位孕妇推算出其完整的达标时间 (T_{attain})。本文选择高斯过程回归 (GPR) 作为核心预测工具，推算出孕妇 T_{attain} 的后验分布。第二阶段将问题形式化为一个组合优化问题，并选择遗传算法 (GA) 进行优化，得到最优的 BMI 区间及其对应的静态最佳 NIPT 时点。

2.3 问题三的分析

问题三引入了更多维度，模型必须从依赖单一的 BMI 变量升级为能够综合处理多维异构特征的复杂模型。其次，决策目标需要构建一个与“达标比例”动态挂钩的、连续的 NIPT 策略函数。

为此引入生存分析作为核心理论框架，将预测目标转变为“随时间变化的累积达标概率函数”，契合“达标比例”的动态要求，并能科学处理观测删失数据。在此框架下，我们选择构建一个混合深度生存网络作为核心代理模型，预测达标时点。而后再次建立风险模型，并用遗传算法解出分组与最佳时点。

2.4 问题四的分析

问题四旨在建立数据驱动的女胎异常判定方法。本文构建了基于 LightGBM 的堆叠集成诊断模型，采用两阶段判断流程。首先进行多专家模型构建与特征融合，考虑到女胎 NIPT 数据中各指标间存在复杂相关性，以及单一方法对复合异常识

别能力的局限性，采用四个专项模型协同架构：以交互影响模型及三个专项模型作为核心模块，结合关键原始特征构建混合特征空间。在此基础上，进行元学习优化与逻辑修正，最终得到优化的女胎染色体异常判定模型。

针对以上问题，本文采用了以下整体思路框架进行系统性研究和分析：

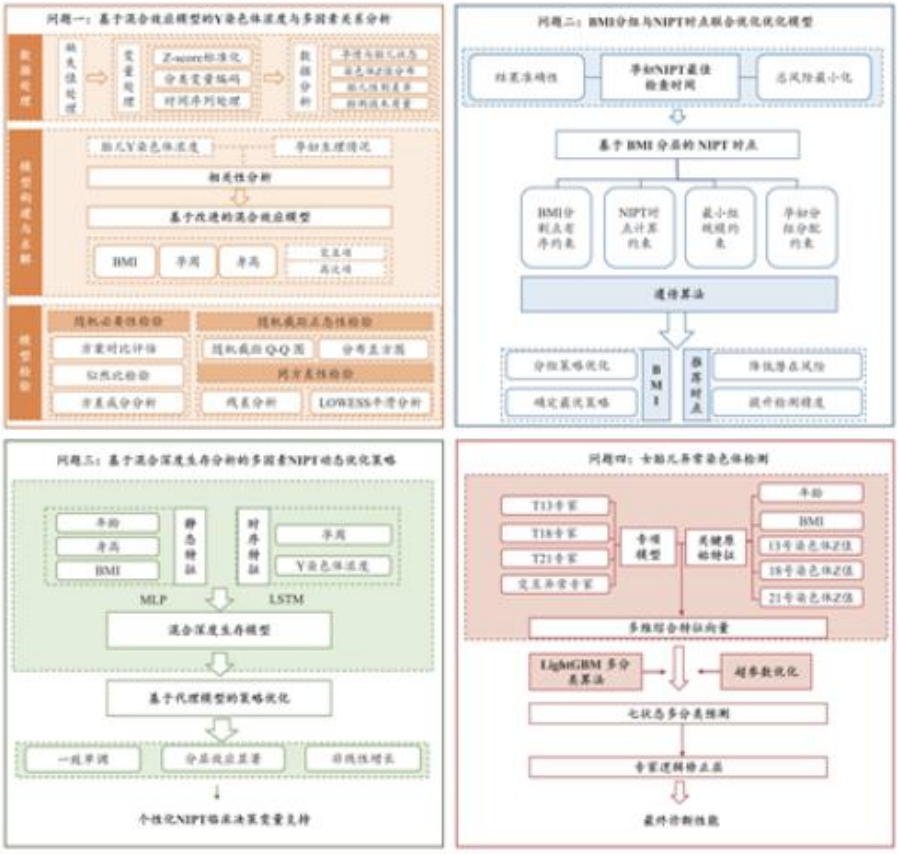

图 1　总体思路框架

三、　模型假设

1. 孕妇虽然在年龄、BMI、孕情等方面存在个体差异，但这些差异在统计学上是可建模和可预测的，不存在极端异常个体影响整体模型效果。
2. NIPT 检测的临床有效性阈值普遍被认定为胎儿 Y 染色体浓度达到或超过 4%，若低于该阈值，检测结果的准确性则难以满足要求。
3. 对于同一孕妇的多次检测，假设每次检测在技术上相互独立，检测误差符合正态分布，可通过统计方法进行综合评估。
4. 所有检测数据都源自标准化的实验室流程，具备统一的质量控制标准，测序深度、比对质量等技术参数在可接受范围内变化。

五、 数据预处理

原始数据包含男胎检测数据 1082 条记录和女胎检测数据 605 条记录，共计 1687 条临床检测记录，涵盖 31 个原始特征维度。作为医疗样本数据，所有数值均代表真实的临床检测结果。

5.1 缺失值处理

通过缺失值统计分析，发现男胎数据不存在缺失值，女胎数据仅 BMI 数据存在一个缺失值，使用拟合方式进行填充。与男胎数据相比，女胎数据由于生物学特性缺少 Y 染色体相关指标，属于结构性差异而非数据缺失。

5.2 数据类型清洗与标准化

5.2.1 连续变量标准化处理

为消除身高和体重在量纲和数值范围上的差异对后续建模的影响，对孕妇的身高、体重两个基本生理指标采用 Z-score 标准化方法进行归一化处理。标准化变换公式为：

$$Z = \frac{X - \mu}{\sigma} \tag{1}$$

其中 Z 为标准化后的值，X 为原始观测值，μ 为样本均值，σ 为样本标准差。通过标准化处理，使身高、体重数据转换为均值为 0、标准差为 1 的标准正态分布。

5.2.2 分类变量映射处理

针对数据样本中的分类变量，采用数值编码方法将文本类别转换为数值形式。编码方案如下：

(1) IVF 妊娠：二元分类变量，映射为 {0 : 自然受孕, 1 : IVF 试管婴儿}

(2) 怀孕次数：离散分类变量，根据频次分布进行有序编码

(3) 胎儿是否健康：二元分类变量，映射为 {0 : 否, 1 : 是}

5.2.3 时间变量数值化

将" 孕妇本次检测时的孕周" 列从文本格式（如"16w+1", "16W+1", "16w"）转换为以周为单位的数值变量。转换规则为：

$$\text{孕周数值} = \text{周数} + \frac{\text{天数}}{7} \tag{2}$$

5.3 数据分析

本节对处理后的数据进行全面分析。为了获得更全面的统计结果，将男胎和女胎的检测数据进行合并处理，通过多维度的可视化图表深入探讨染色体异常检

全国大学生在线 dxs.moe.edu.cn

测、孕妇健康状况与胎儿发育关系、性别差异以及检测技术质量等关键问题，为临床诊断和质量控制提供数据支撑。

5.3.1 孕妇健康状况与胎儿发育关系分析

本小节重点分析孕妇年龄和 BMI 等关键因素对胎儿异常率的影响。图2通过柱状图展示了不同年龄段和 BMI 分组的胎儿异常率分布。

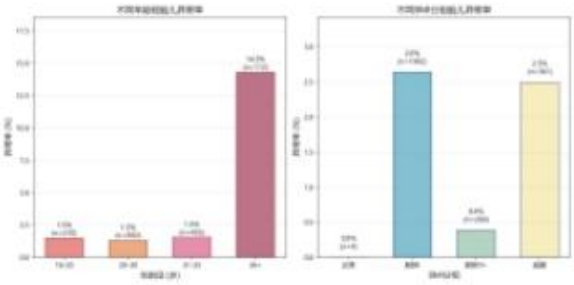

图 2　孕妇健康状况与胎儿发育关系分析

从图2可以看出，年龄因素对胎儿异常率有显著影响。18-35 岁组均在 1.5% 附近，而 36 岁以上高龄组异常率显著升高至 14.3%。在 BMI 分组分析中，正常 BMI 组异常率为 0%，肥胖 I 级组异常率为 2.6%，肥胖 II 级以上组为 0.4%，超重组为 2.5%。数据表明，避免肥胖状态可有效降低异常发生率。

5.3.2 染色体 Z 值分布特征分析

本节通过箱线图对各主要染色体的 Z 值分布进行了深入分析。图3展示了 13、18、21 号染色体及 X 染色体在健康与异常胎儿中的 Z 值分布特征，揭示了不同染色体异常检出的统计规律。

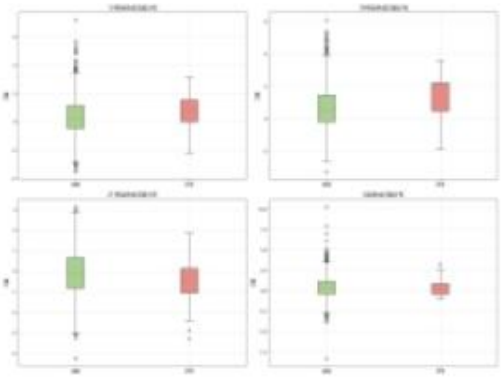

图 3　染色体 Z 值分布分析

从图3可知，各染色体 Z 值在健康与异常胎儿间呈现明显差异。18 号染色体异常检出率最高，达 4.68%。13 号染色体异常率为 2.55%，Z 值分布相对集中。21

号染色体异常率最低，仅 0.41%，但其异常样本 Z 值变化幅度较大。X 染色体异常率为 3.08%，在性别鉴定中起重要作用。

5.3.3 胎儿性别差异分析

本小节重点分析了男女胎儿在孕妇年龄、BMI、身高等关键指标上的分布差异。通过直方图和箱线图的呈现：

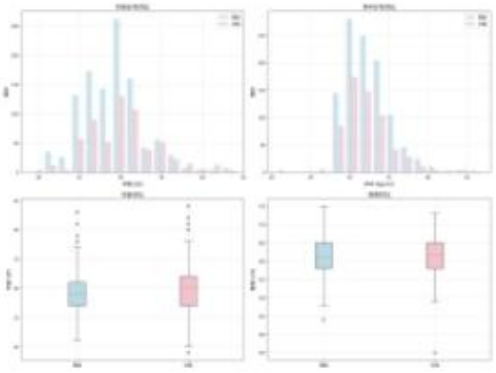

图 4 胎儿性别差异分析

从图4来看，男女胎儿在孕妇年龄分布上基本相似，主要集中在 25-35 岁的最佳生育年龄段。怀男胎和女胎的孕妇 BMI 与身高均值差异并不不显著；而年龄箱线图显示怀女胎孕妇年龄分布更为集中，中位数更高，猜测高龄孕妇可能生育女胎的概率更高。

5.3.4 检测技术质量分析

本小节从技术质量角度分析 NIPT 检测的可靠性，重点关注 GC 含量分布、正常率以及各染色体异常检出比例。图5提供了技术质量评估的全方位视角。

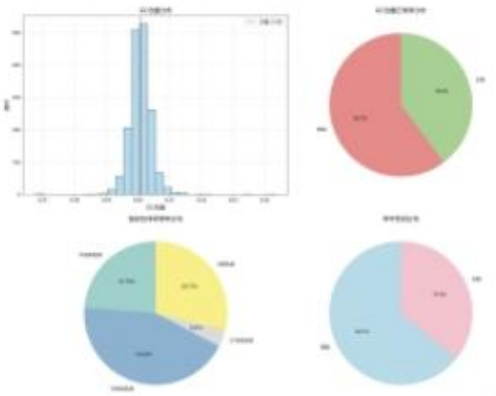

图 5 检测技术质量分析

中国大学生在线 dxs.moe.gov.cn

图5显示，GC 含量基本呈正态分布，表明检测过程的技术稳定性良好。GC 含量正常率为 39.8%，异常率为 60.2%，这一比例在 NIPT 检测中属于正常范围，反映了测序质量控制的有效性。在染色体异常分布中，18 号染色体异常占比最高，其次是 X 染色体、13 号染色体和 21 号染色体。

六、 问题一的模型建立与求解

6.1 相关性分析

为确保模型输入的准确性和后续模型求解的可行性，在建立 NIPT 的时点选择与胎儿的异常判定模型前，需要对各关键变量进行全面的相关性分析。本节通过多维度的统计分析，深入探讨 Y 染色体浓度与各影响因素之间的关系模式。

首先，基于男胎检测的 1082 个样本的统计分析显示：Y 染色体浓度呈右偏分布，数据集中在 0.05-0.15 区间；检测时间呈正态分布，时间跨度 11-29 周；体质量指数 BMI 呈右偏分布，多数孕妇 BMI 在 28-38 之间，标准化效果良好。

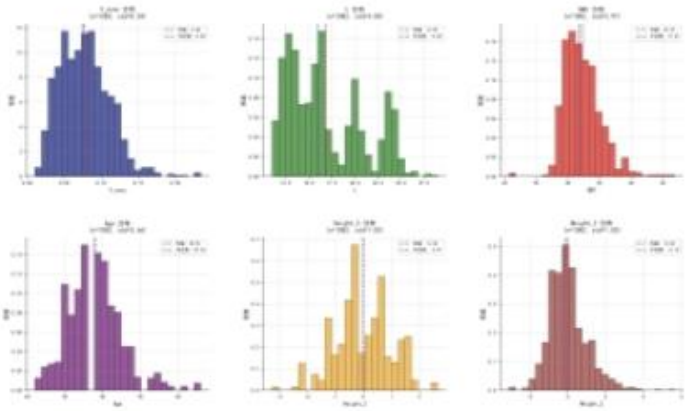

图 6　核心变量分布特征与统计描述

从图6可以看出，数据经过预处理后各变量分布符合预期，均值和方差表现稳定。在此基础上，进一步对核心变量间的相关性进行深入分析。

结果初步表明：孕周 t 与 Y 染色体浓度呈显著正相关，BMI 与 Y 染色体浓度呈负相关，标准化身高 Height_Z 与 Y 染色体浓度呈负相关；同时大多数数据样本均显示随着检测抽血次数 BloodNum 的增加，Y 染色体浓度也会呈现上升趋势，为问题二中确认最早达标孕周的三阶段分层决策提供支撑。

中国大学生在线 dxs.moe.gov.cn

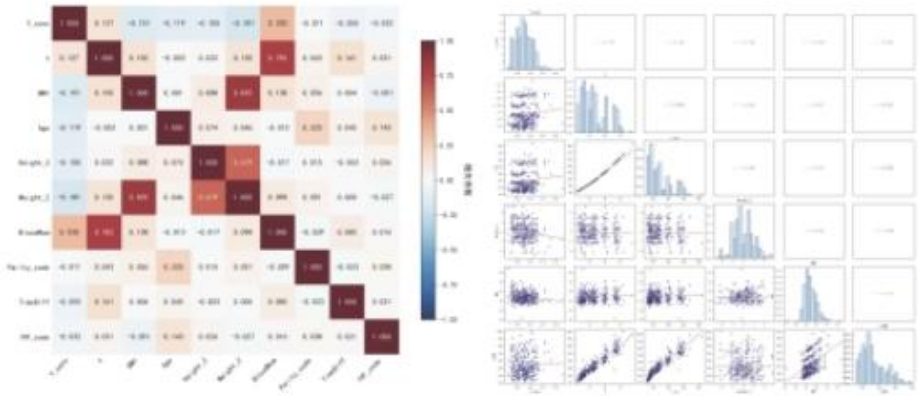

(a) 核心变量相关性热力图　　(b) 变量间关系综合矩阵图

图 7　变量相关性分析

散点图矩阵在原先基础上，进一步增加高次项，发现孕周二次项 t^2 与 Y 染色体浓度存在显著正相关性，表明时间效应可能存在非线性特征。同时，BMI 与 Weight_Z 之间的强相关性，使得后续模型建立时，需要谨慎考虑变量间的多重共线性问题。

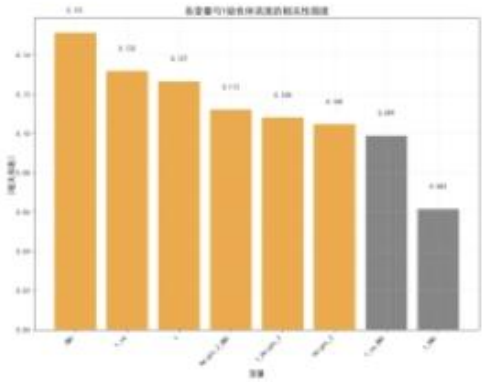

图 8　Y 染色体浓度相关性强度

最后，将各变量与 Y 染色体浓度的相关性强度展示如上图8。其中，不难看出，针对于交互项对 Y 染色体浓度的影响程度存在显著差异。该结果为下一小节模型设定提供一定的参考价值。

6.2　关于线性混合效应模型的设定

在样本数据观测值中分为两个层次，第一层为检测记录层，第二层为孕妇个体层。具体表现为：同一孕妇可能存在多次采血检测或一次采血多次检测的情况。因此，形成了多个检测记录嵌套在同一个孕妇个体内的数据结构。这种数据结构

会引发两个问题：第一，同一孕妇的多次 Y 染色体浓度测量值之间必然存在相关性，违背了传统线性回归中观测值独立性的基本假设；第二，不同孕妇由于个体差异可能存在系统性的基线差异，即个体间异质性。

线性混合效应模型（linear mixed model，LMM）是专门用于处理此类分层数据的统计方法，该模型通过引入随机效应项来捕捉个体层面的随机变异，同时保留固定效应项来估计总体层面的平均效应，从而能够同时处理个体内相关性和个体间异质性问题，确保统计推断的有效性和准确性。其基本形式为：

$$Y_{ij} = X_{ij}\beta + Z_{ij}b_i + \epsilon_{ij} \tag{1}$$

其中 Y_{ij} 为第 i 个个体第 j 次观测值，$X_{ij}\beta$ 为固定效应，$Z_{ij}b_i$ 为随机效应 $(b_i \sim N(0, D))$ ，$\epsilon_{ij} \sim N(0, \sigma^2)$ 为随机误差。

Step 1：构造 Y 染色体浓度与孕周数和 BMI 的基准模型

从已有文献和相关性分析不难看出，Y 染色体浓度与孕周及 BMI 存在紧密联系。基于生理机制分析，高 BMI 孕妇因母体血容量增大可能导致胎儿 DNA 稀释，从而减弱孕周效应，故引入 $t \times BMI$ 交互项；同时考虑到可能存在的非线性关系，引入 t^2 和 BMI^2 二次项，初始模型设定如下：

$$Y_{ij} = \beta_0 + \beta_1 \times t_{ij} + \beta_2 \times BMI_{ij} + \beta_3 \times t_{ij}^2 + \beta_4 \times BMI_{ij}^2 + \beta_5 \times (t_{ij} \times BMI_{ij}) + \mu_j + \varepsilon_{ij} \tag{2}$$

通过逐步添加各项并进行显著性检验，对所有可能组合（共 8 种）进行比较。结果显示，t_{ij}^2 项系数 β_3 达到 $P < 0.001$ 显著性水平，纳入最终模型；而 BMI_{ij}^2 项和交互项 $(t_{ij} \times BMI_{ij})$ 系数均未达到 $P < 0.05$ 显著性水平。根据奥卡姆剃刀原理，剔除不显著项以避免过度参数化。因此，将 BMI_{ij}^2 项和交互项 $(t_{ij} \times BMI_{ij})$ 从模型中删除。

Step 2：构造纳入其他指标的扩展模型

为了进一步探索可能影响 Y 染色体浓度的其他因素，采用逐步回归的方法，对孕妇的其他生理指标进行显著性检验。通过统计分析发现，身高的一次项达到显著性水平，因此将其纳入最终模型。经过变量筛选和模型优化后，得到的最终模型结果如下：

$$Y_{ij} = \beta_0 + \beta_1 \times Height_{ij} + \beta_2 \times t_{ij} + \beta_3 \times BMI_{ij} + \beta_4 \times t_{ij}^2 + \mu_j + \varepsilon_{ij} \tag{3}$$

6.3 模型求解

本小节采用限制性最大似然估计（REML）方法对线性混合效应模型进行参数估计，该方法在处理不平衡数据和小样本情况下具有更好的统计性质。表1展示了固定效应的详细估计结果。

中国大学生在线 dxs.moe.gov.cn

表 1　固定效应估计结果

变量	系数估计	标准误	z 值	p 值
t	−0.003014	0.0013211	−2.28	0.023
t^2	0.0001701	0.0000363	4.68	0.000
$Height_Z$	−0.0038334	0.0018705	−2.05	0.040
BMI	−0.0013541	0.0005159	−2.62	0.009
常数项	0.1213106	0.0197865	6.13	0.000

固定效应的联合显著性检验采用 Wald χ^2 检验，统计量为 $\chi^2(4) = 440.90, p < 0.001$，在 0.001 的显著性水平下拒绝所有固定效应系数均为零的原假设，表明至少有一个预测变量对 Y 染色体浓度具有显著影响。

（1）孕周非线性效应分析

孕周二次项（t^2）系数为 0.0001701，线性项（t）系数为-0.003014，分别在 99% 和 95% 水平下显著。正的二次项系数与负的线性项系数形成 U 型非线性关系，理论转折点为 $t_{min} = -\frac{\beta_1}{2\beta_2}$。由于观测孕周均在 10 周以上，观测到 U 型曲线右侧递增部分，表现为 Y 染色体浓度随孕周加速增长且增长的速度越来越快。

（2）孕妇个体特征效应分析

标准化身高（$Height_Z$）在 99% 水平下显著，回归系数表明身高每增加 1 个标准差，Y 染色体浓度降低 0.38334%，可能与血液稀释效应相关。

BMI 在 99% 水平下显著，其系数为-0.0013541，表明 BMI 每增加 1 kg/m^2，Y 染色体浓度降低 0.13541%。该负向关系反映 BMI 较高孕妇因血容量增加导致 Y 染色体浓度相对稀释。

6.4　模型检验

6.4.1　随机效应必要性检验

随机效应的必要性检验是验证线性混合效应模型相对于普通线性回归模型优势的关键步骤。我们通过多种方法评估了在模型中纳入随机截距的必要性。

（1）模型比较结果

表2展示了线性混合效应模型与固定效应模型的详细比较结果。

表 2　混合效应模型与固定效应模型比较

指标	混合效应模型	固定效应模型
样本量	1,082	1,082
对数似然值	2547.5722	2171.4381
AIC	−5081.1444	−4330.8762
BIC	−5046.2385	−4300.9568
参数个数	7	5

中国大学生在线 dxs.moe.gov.cn

从模型比较结果可以看出，混合效应模型在所有拟合指标上均显著优于固定效应模型。对数似然值从 2171.4381 提升至 2547.5722，增幅达 376.1341，表明混合效应模型对数据的拟合能力大幅改善。此外，尽管混合效应模型增加了 2 个参数，但其 AIC 值和 BIC 值均远低于固定效应模型，表明考虑惩罚项后，混合效应模型仍具有明显优势。

（2）似然比检验

混合效应模型内置的似然比检验结果显示：$\chi^2(1) = 752.27, p < 0.001$，强烈支持随机截距的必要性。该检验统计量极大且 p 值小于 0.001，表明随机效应方差显著不为零，拒绝了" 无需随机效应" 的零假设。

（3）方差成分分析

随机截距方差 $\sigma_u^2 = 8.24 \times 10^{-4}$，残差方差 $\sigma_e^2 = 2.85 \times 10^{-4}$。组内相关系数为：

$$ICC = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_e^2} = \frac{0.000824}{0.000824 + 0.000285} = 0.743 \tag{4}$$

ICC = 0.743 表明约 74.3% 的总变异来源于孕妇间差异，同一孕妇内部的重复测量之间存在强烈的相关性，约四分之三的总变异来源于孕妇间的个体差异。该结果证明了数据的聚类特征，使用普通线性回归会严重低估标准误，导致统计推断出现错误。

6.4.2 随机截距正态性检验

混合效应模型的一个重要假设是随机效应服从正态分布。为验证随机截距的正态性假设，本研究采用 Q-Q 图和直方图两种方法进行诊断。

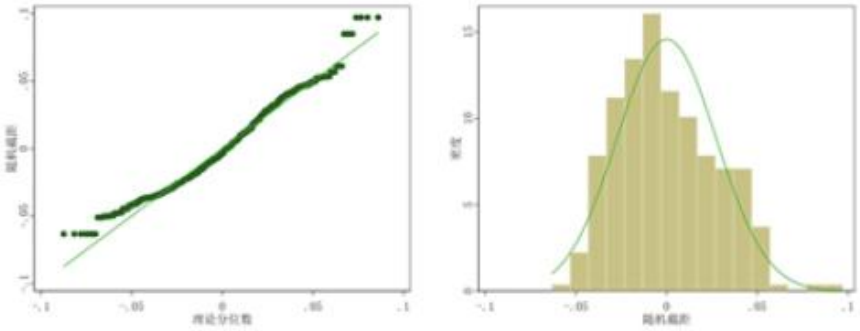

(a) 随机截距 Q-Q 图　　(b) 随机截距分布直方图

图 9　随机截距正态性检验

从图9的诊断结果可以看出，随机截距基本满足正态分布假设。Q-Q 图显示大部分观测点紧密分布在理论直线附近，仅在右尾部分存在轻微偏离；分布直方图呈现良好的钟形特征，与理论正态曲线高度吻合，分布中心接近零且基本对称。

这些结果表明混合效应模型中随机截距的正态性假设得到较好满足，为模型推断的有效性提供了支撑。

6.4.3 同方差性检验

同方差性是线性混合效应模型的重要假设之一，要求残差的方差在不同拟合值水平上保持相等。我们通过多角度的图形分析对这一假设进行了全面检验。

图10展示了四种不同类型的残差与拟合值关系图：

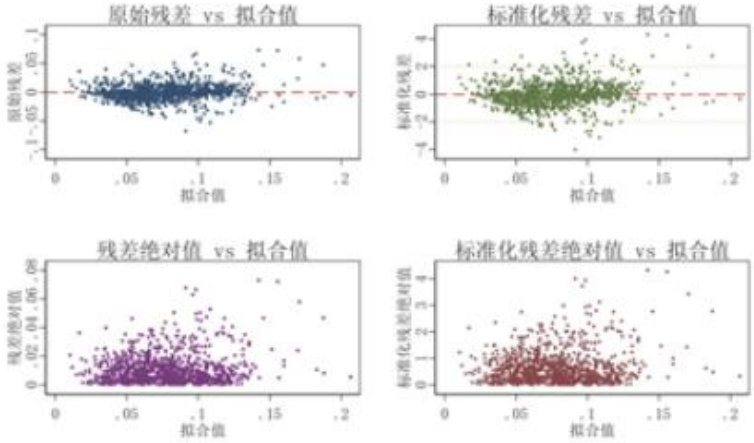

图 10　同方差性检验

上图表明，原始残差围绕零线随机分布，且集中在 ±0.05 范围内，标准化残差大部分位于 ±2 标准差内，残差绝对值无明显递增或递减趋势。因此，残差分布基本符合同方差性假设要求，异常值呈随机分布，支持同方差性假设。

图11展示了带有 LOWESS 平滑曲线的残差分析，用于检验系统性偏差和非线性模式：

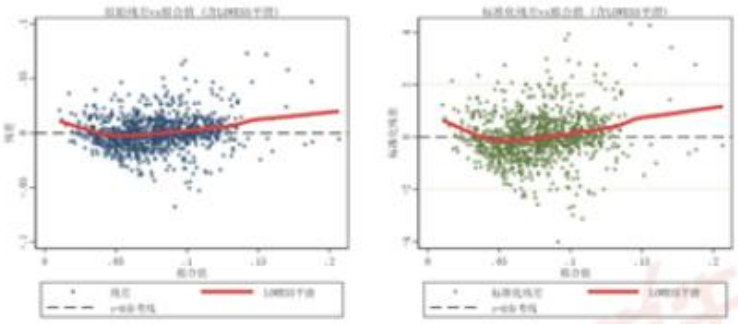

图 11　LOWESS 平滑分析

LOWESS 平滑分析显示，原始残差和标准化残差的平滑曲线均在零线附近小

中国大学生在线 dxs.moe.gov.cn

幅波动，虽然存在轻微的 U 型模式，但偏离程度很小，表明当前的二次项设定基本充分，无明显的模型设定偏误，系统性偏差可忽略。

综合上述诊断结果，模型残差分布基本符合同方差性假设，结合线性混合效应模型的稳健性特征，当前模型的同方差性假设得到较好支持。